

MiniAutoML

KGBClassifier

Mateusz Brochocki

Aleksander Karch

Adrian Krzyżanowski



Modele składowe

CatBoost

- Model drzewiasty
- Brak konieczność one-hot encodingu i skalowania danych
- Bardzo dobre wyniki dla "typowych" danych
- Fitowanie zajmuje sporo czasu

Regresja logistyczna

- Model liniowy
- Regularyzacja l1 i l2
- Konieczność one-hot encodingu i uzupełnienia braków
- Trzeba wykonać skalowanie danych

kNN i SVM

- Działają dobrze dla rozdzielonych danych
- Konieczność one-hot encodingu i uzupełnienia braków
- Trzeba wykonać skalowanie danych

Dobór CatBoostów


- Wykorzystanie optymalizacji TPE oraz pakietu **optuna** do poszukiwania optymalnych hiperparametrów
- Wybór 45 najbardziej optymalnych modeli
- Po 15 CatBoostów dla różnego stopnia rozbudowania modelu (małe - 10 drzew, średnie - 20 drzew, duże - 200 drzew)
- Ręczne odrzucenie 7 z nich ze względu na zbyt długi czas wykonania
- Ostatecznie 38 CatBoostów

Dobór pozostałych modeli


- Poszukiwanie optymalnych hiperparametrów na 40 zbiorach danych (10 małych, 10 średnich, 10 dużych, 10 z dużą liczbą zmiennych)
- Optymalizacja dwóch najważniejszych hiperparametrów (jeden w przypadku SVM)
- Dwukrokowa optymalizacja hiperparametrów z wykorzystaniem *GridSearchCV* i *RandomSearchCV*
- Ostatecznie 12 modeli (4 regresje, 4 kNN i 4 SVM)

Metoda dwukrokowa

Średnia z miejsc zajętych przez modele elasticnet z parametrem C dla 10 zbiorów



Średnia z miejsc zajętych przez modele elasticnet z parametrem l1_ratio dla 10 zbiorów



Ogólne działanie systemu

- Wykonanie dwóch rodzajów preprocessingu, oddzielnie dla Catboostów i dla pozostałych modeli
- Pierwsze 14 minut na wykonanie CatBoostów
- Kolejne 2 minuty to fitowanie pozostałych modeli
- Ostatnie 4 minuty to tworzenie ensembli (stacking oraz voting (hard i soft))

Tworzenie ostatecznego modelu

- Sprawdzenie miary *balanced accuracy* każdego modelu
- Do stackingu wybierane są 3 losowe CatBoosty + najlepszy z pozostałych modeli + 1 losowy z pozostałych modeli. Finalnym modelem jest najlepszy Catboost
- W votingu zastępujemy jeden losowy Catboost najlepszym Catboostem
- Porównujemy wyniki ensembli (pod warunkiem, że się wykonają) oraz najlepszych pojedynczych modeli i jako ostateczny model używamy najlepszego z nich


Eksperymenty i wnioski

Tabela 1: Pomiary Balanced Accuracy dla różnych pakietów AutoML.

Numer zbioru danych	KGBClassifier	AutoGluon	MLJAR	FLAML
I	0.6776	0.6908	0.6352	0.6542
II	1	1	0.9902	1
III	0.8199	0.8268	0.8056	0.8305
IV	0.9573	0.9762	0.9692	0.9762
V	0.6943	0.677	0.6828	0.7306

Wyniki porównywalne z innymi bibliotekami do automatycznego uczenia maszynowego.

Porównanie Balanced Accuracy



Dziękujemy za uwagę